Avaliação de Desempenho de Programas Paralelos

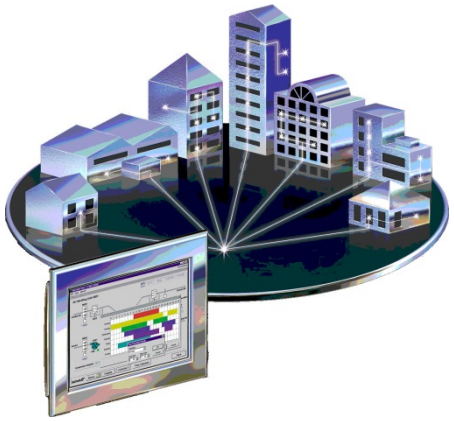

Programação Paralela Avançada - PPA

Mestrado em Computação Aplicação – MCA
Programa de Pós-Graduação em Computação Aplicada – PPGCA
Centro de Ciências Tecnólogicas - CCT
Universidade do Estado de Santa Catarina – UDESC

Profs Maurício A. Pillon e Guilherme P. Koslovski
Linha de Sistemas Computacionais
Grupo de Pesquisa de Redes de Computadore e Sistemas Distribuídos
Laboratório de Pesquisa LabP2D

Avaliação de desempenho de aplicações paralelas

- Mensurar o impacto do paralelismo sob uma determinada aplicação/algoritmo
- Conceitos
  - Aceleração
  - Eficiência
  - Escalabilidade

Avaliação de desempenho de aplicações paralelas

- Algoritmos sequenciais são avaliados em função de seus tempos de execução, normalmente expressos em função do tamanho de sua entrada
- Algoritmos paralelos não dependem exclusivamente do tamanho da entrada sendo também influenciados por suas computações relativas e velocidades de comunicação entre os processos
- **Usando-se duas vezes mais recursos de hardware espera-se que um programa seja executado duas vezes mais rápido!**
- Em programas paralelos isto raramente acontece devido a perdas associadas (overheads) com o paralelismo

Overhead de paralelismo

- Tempo necessário para coordenar as tarefas paralelas
- Tempo para iniciar uma tarefa
  - Identificação da tarefa
  - Procura de um processador
  - Carregamento da tarefa
  - Carregamento dos dados
- Tempo para terminar uma tarefa
- Sincronização
- Uma quantificação precisa destas perdas é essencial para compreender a performance de programas paralelos

Execução sequencial x paralela

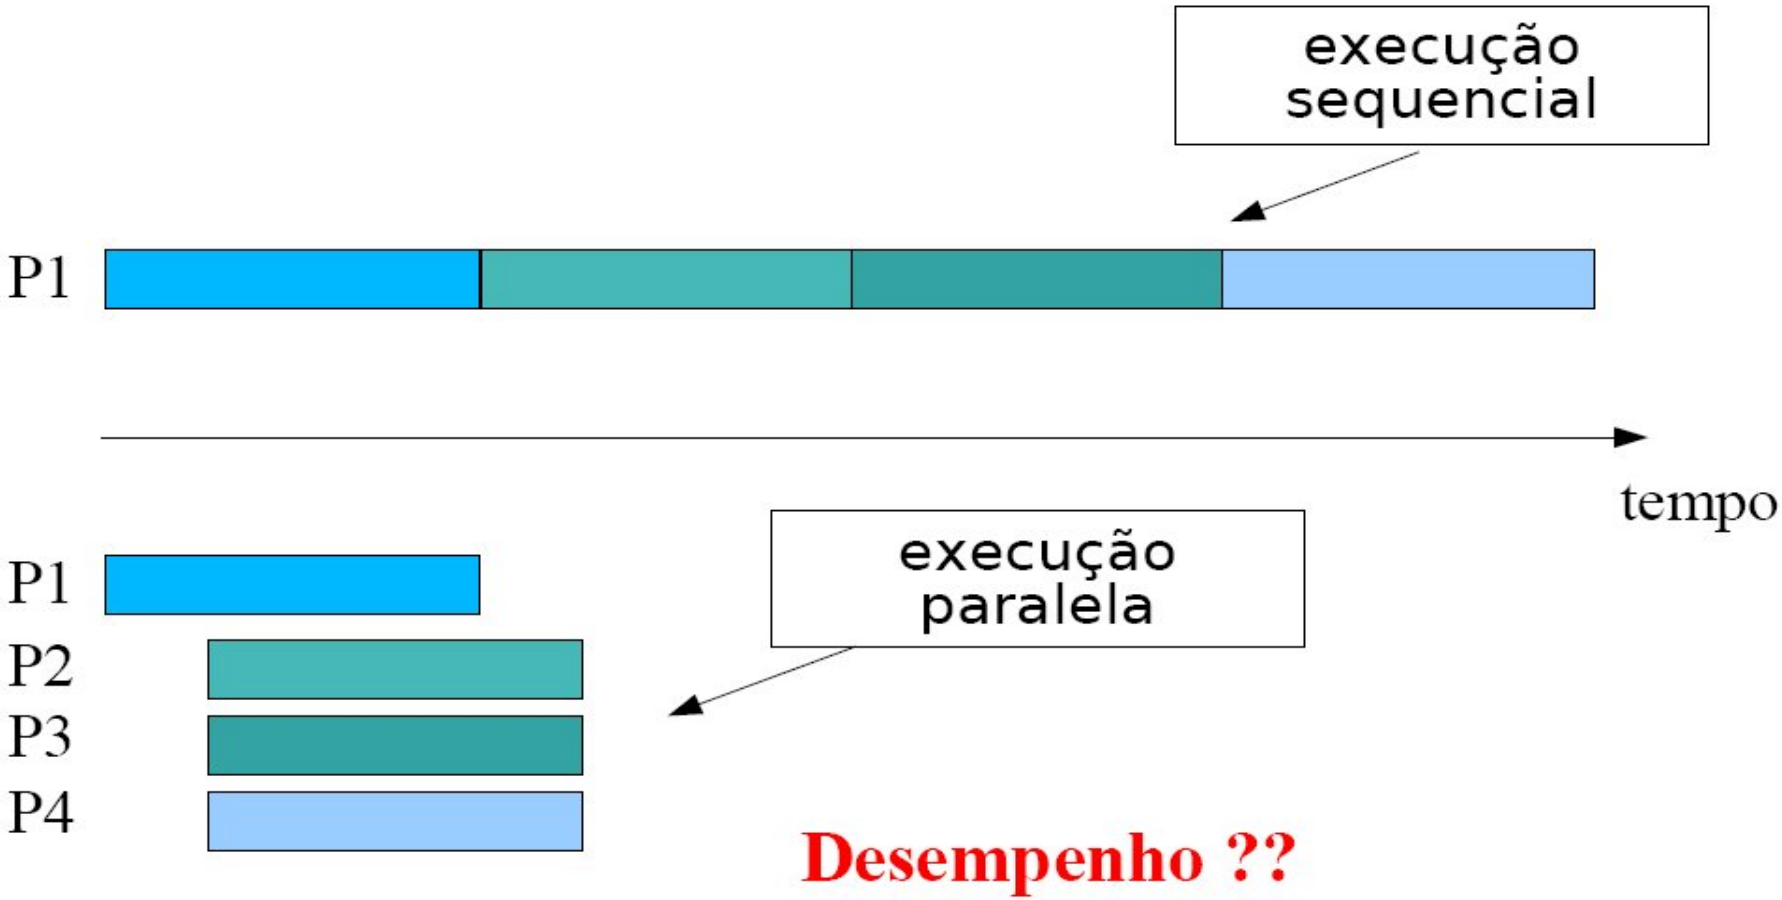

Fontes de perdas

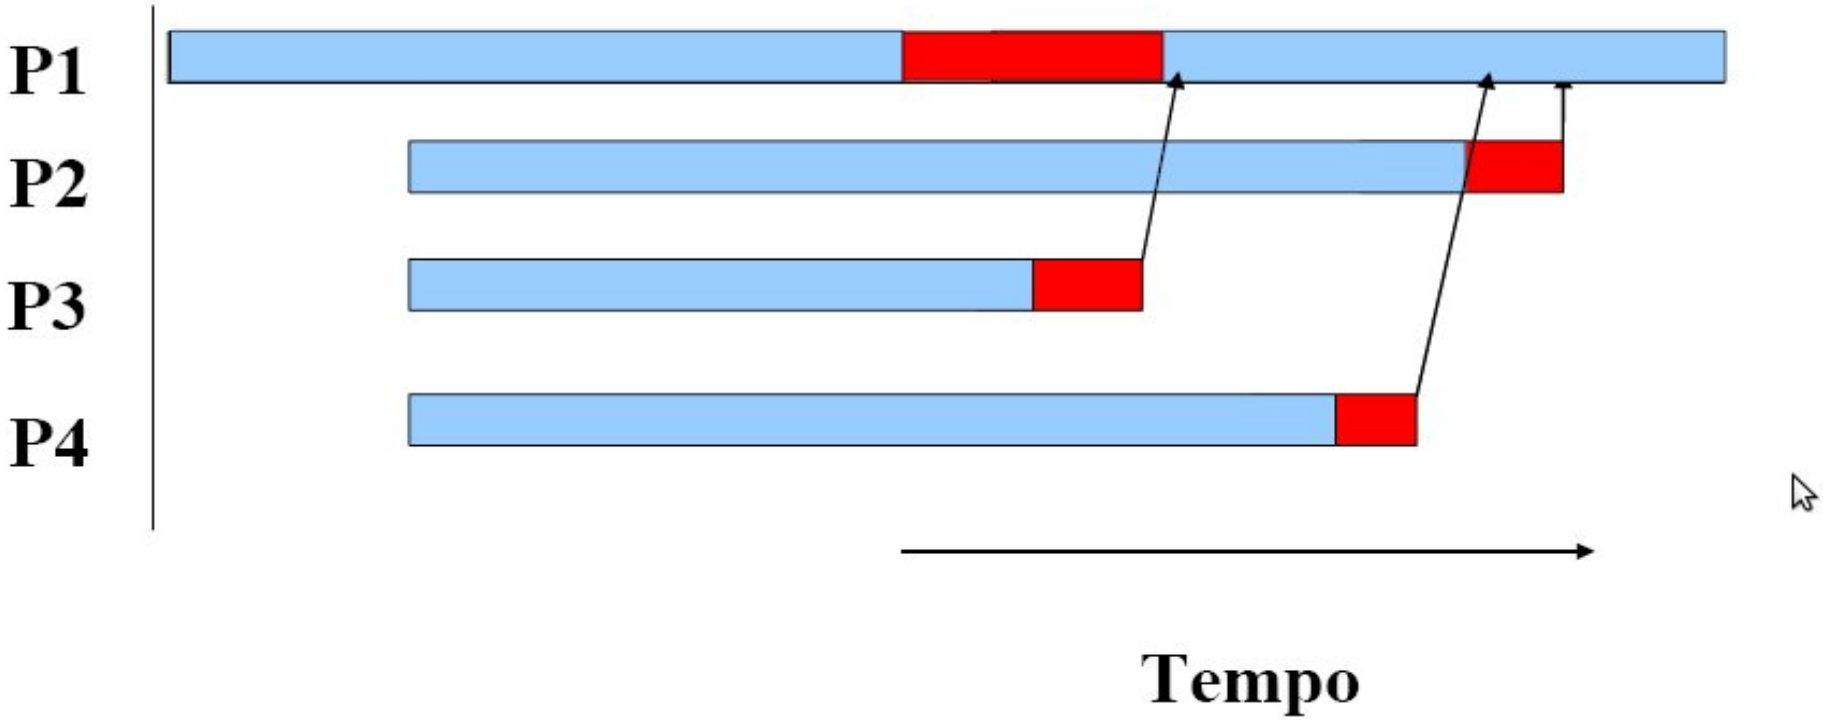

Fontes de perdas

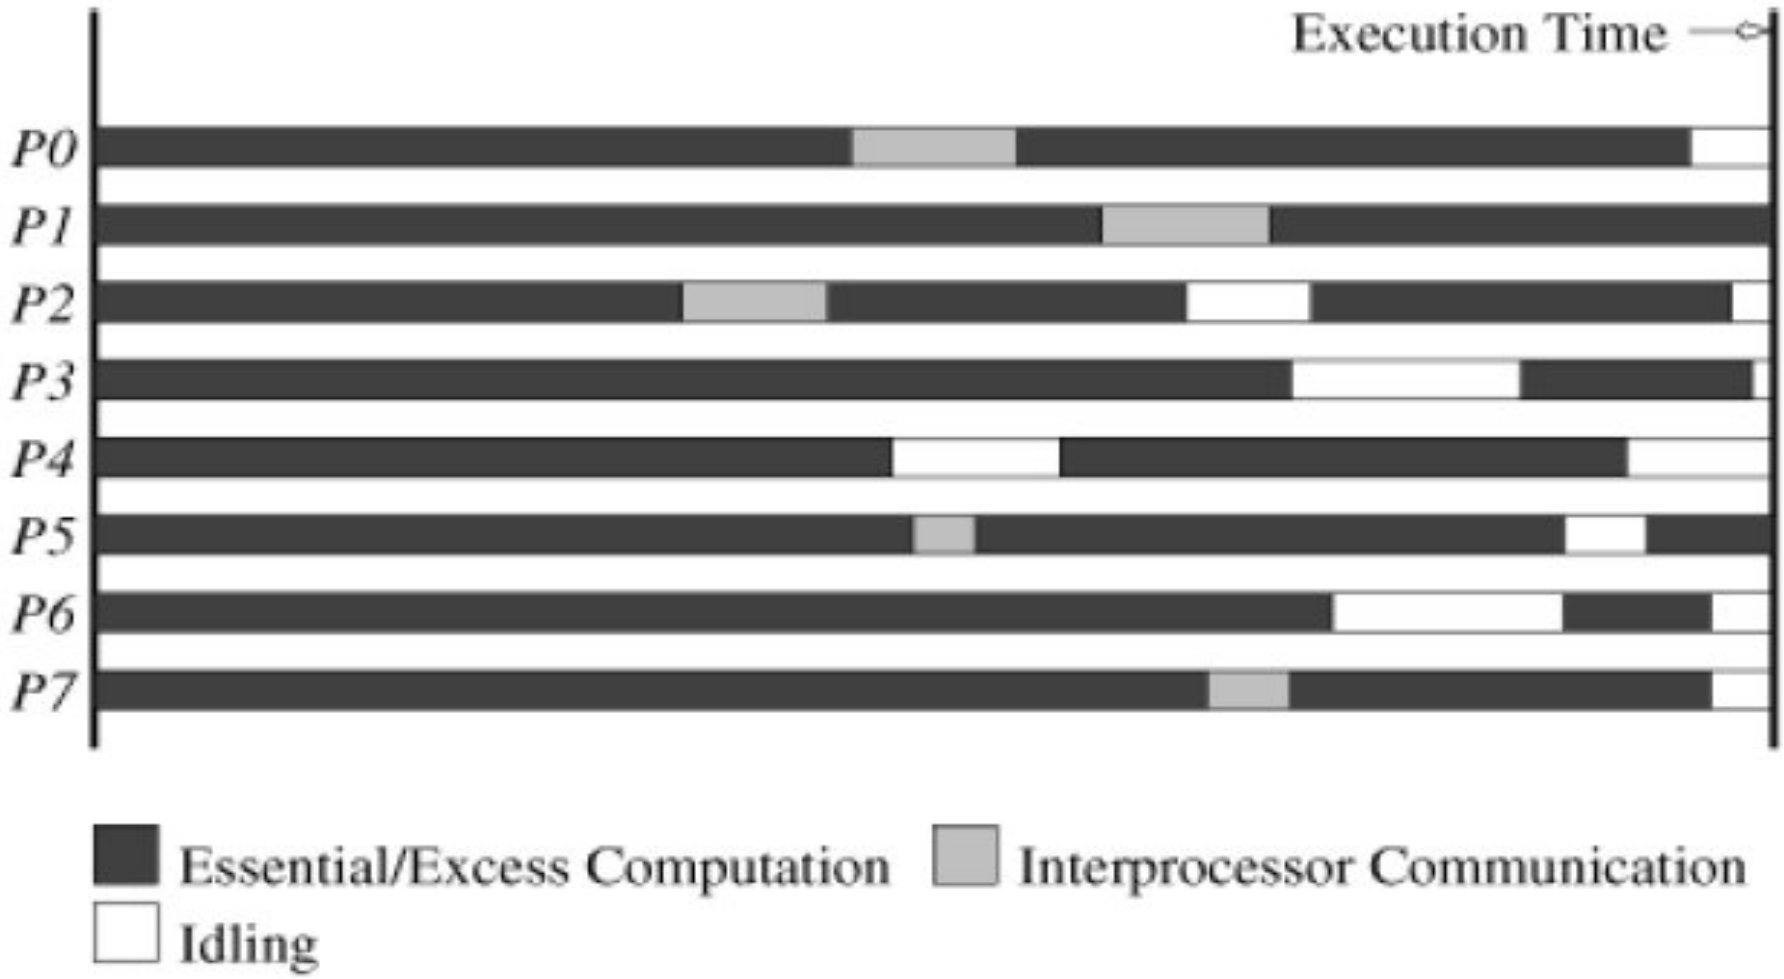

Fontes de perdas

- Interação entre processos
  - Qualquer sistema paralelo não trivial necessita que suas tarefas interajam (comunicação)
  - Geralmente a fonte mais significativa de perdas em processamento paralelo é o tempo gasto em comunicações de dados
- Ociosidade de processadores
  - Desbalanceamento de carga
  - Sincronização
  - Presença de componentes seriais em um programa
- Em muitas aplicações paralelas é impossível predizer o tamanho das subtarefas

Tempo de execução

- Tempo de execução serial (TS)
  - É o tempo decorrido entre o início e o final de sua execução em um computador sequencial
- Tempo de execução paralelo (TP)
  - É o tempo transcorrido entre o início de uma computação paralela até o término do último elemento de processamento
- **Aceleração (*speedup*)**
- S(n) = TS/TP

Speedup: ideal

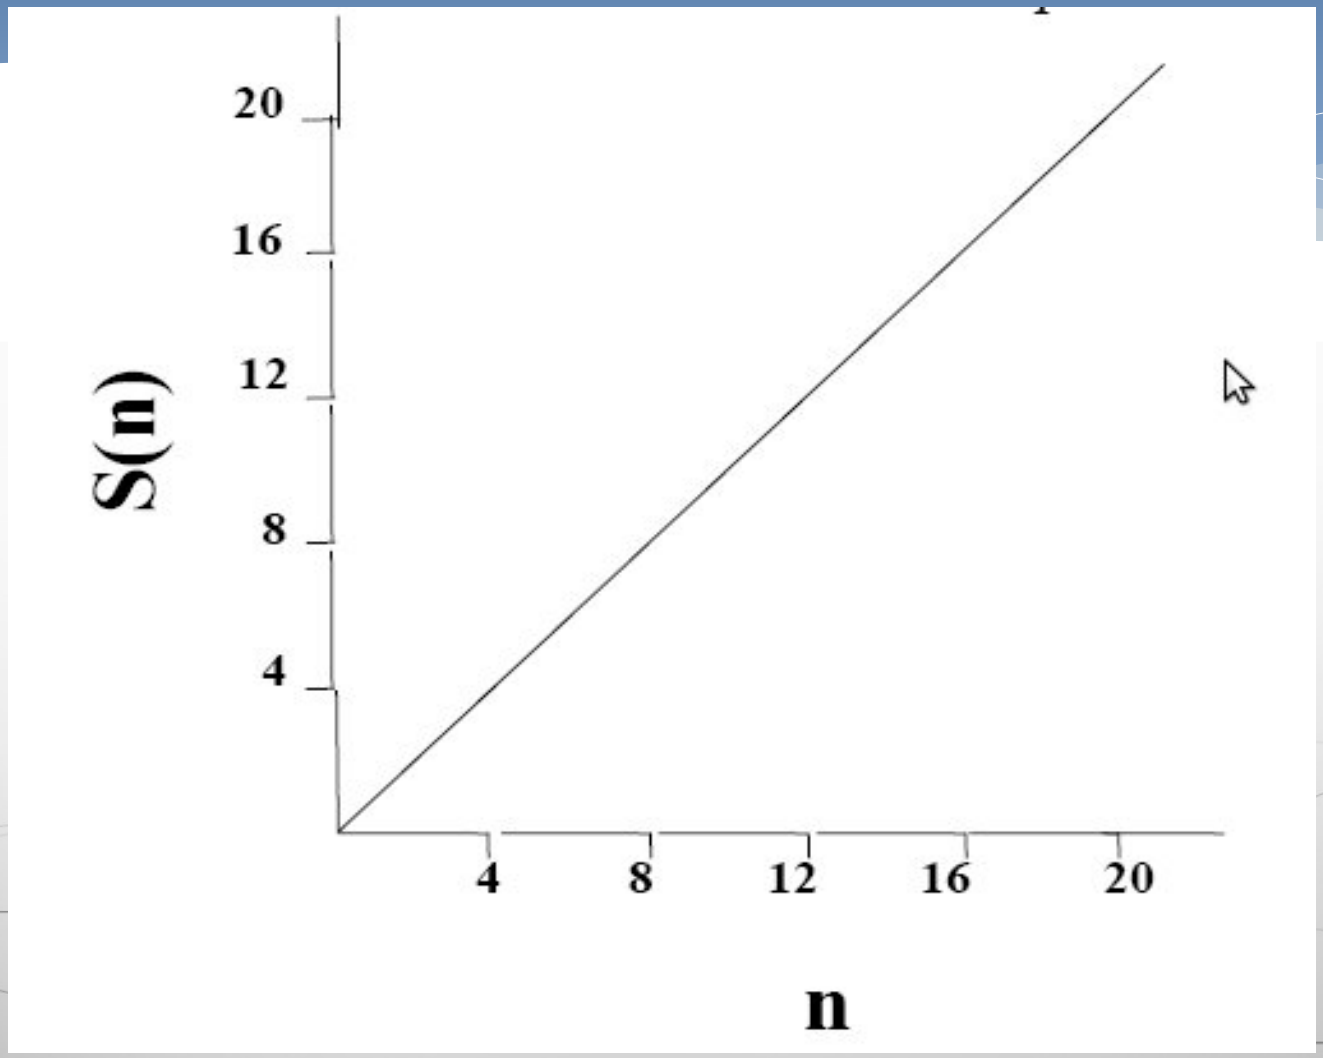

Speedup: limites

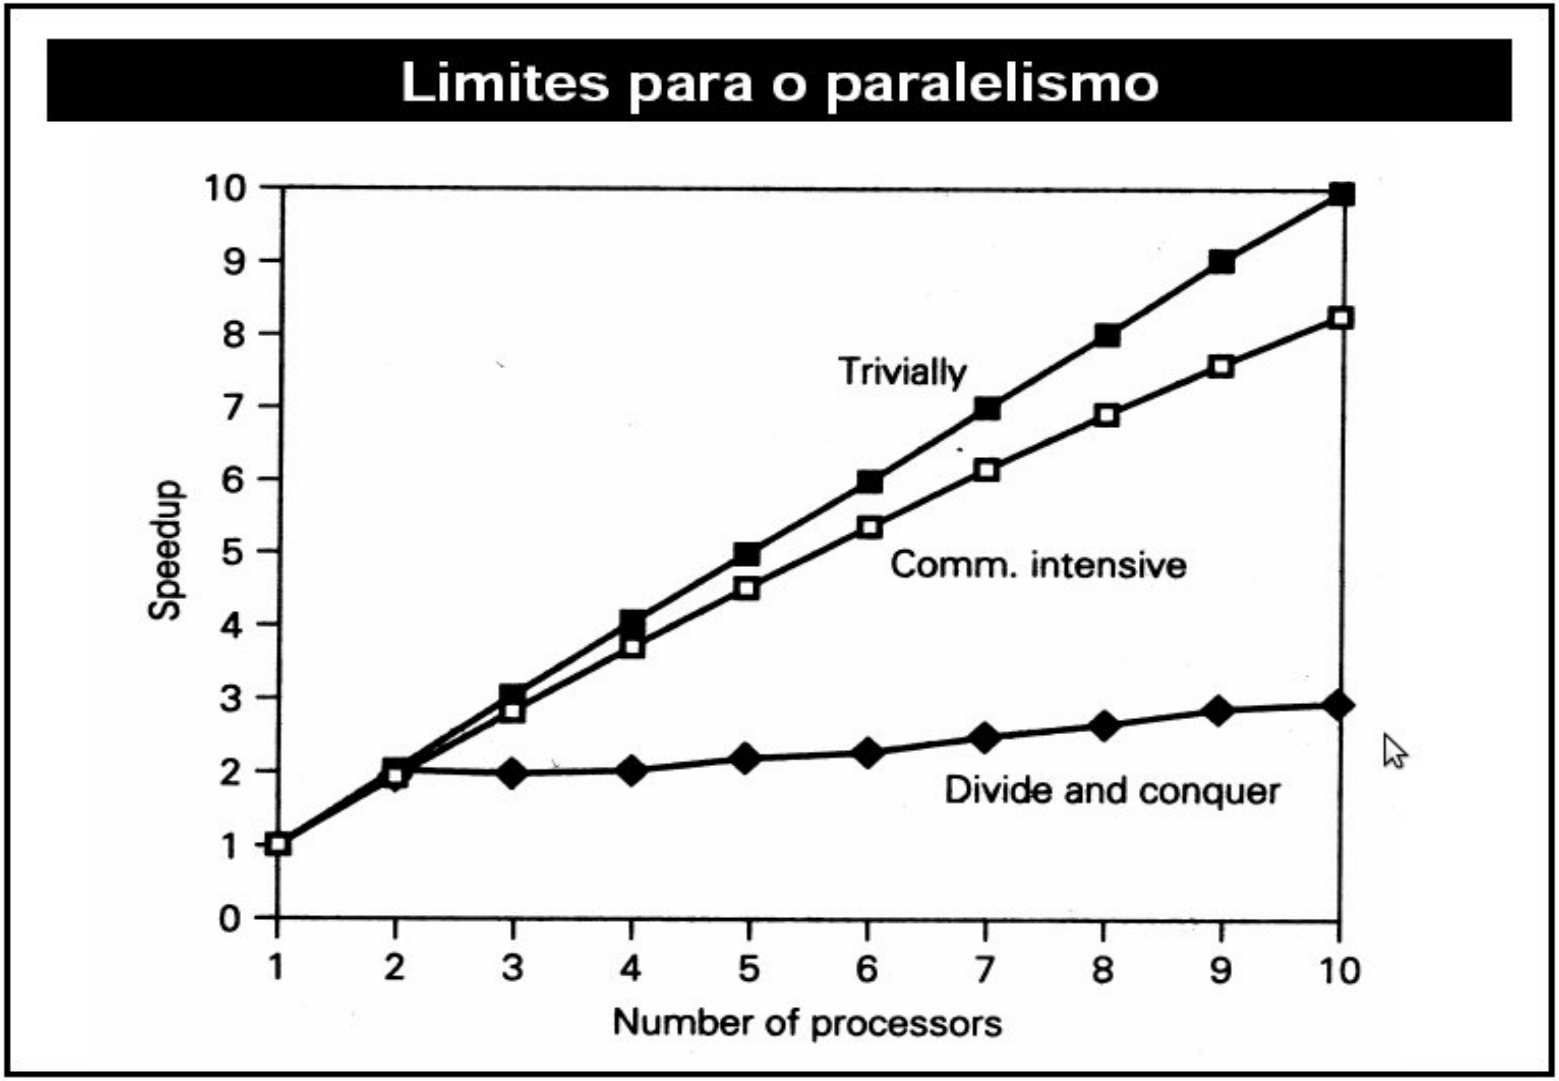

Fonte: Neyal C. Reis Jr.

Eficiência

- É a medida da fração de tempo para o qual um elemento de processamento é empregado de forma proveitosa.
- Razão do speedup e do número de elementos de processamento
- S(n) = speedup
- n = número de processadores
- **E = (S(n) / n) * 100**

Speedup máximo

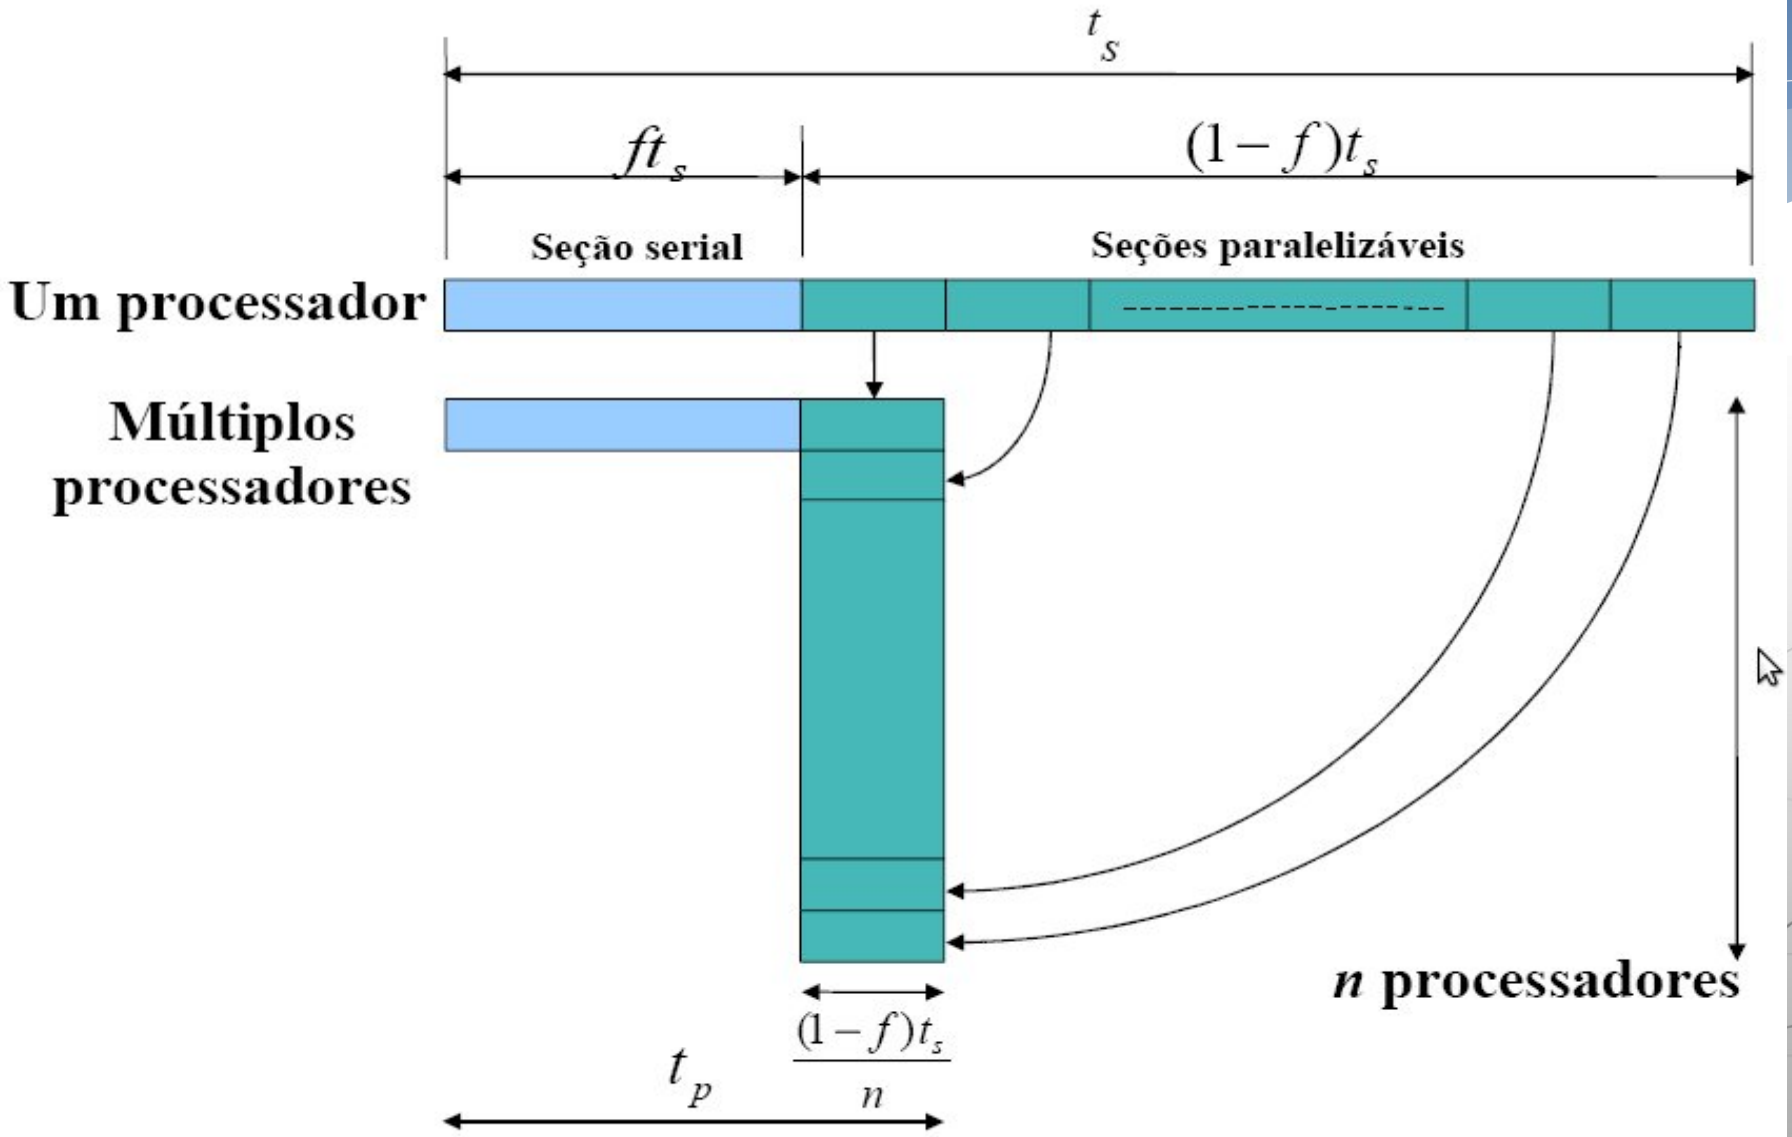

Speedup

- S(n) > n (superlinear)
  - Algoritmo sequencial sub-ótimo
  - Característica particular da arquitetura da máquina paralela
- S(n) < n (sub-ótimo)
  - Lei de Amdahl
  - Sobrecarga do paralelismo

Amdahl's law

- Considera que o tamanho do problema é fixo
- Speedup é limitado pela fração serial

- Speedup = 1 / (s + p/N)
  - s = fração sequencial
  - p = fração paralela
  - N = número de processadores
  - s + p = 1
  - Max speed up = 1/s

Amdahl's law

- Mesmo com número infinito de processadores a aceleração é limitada a 1/s

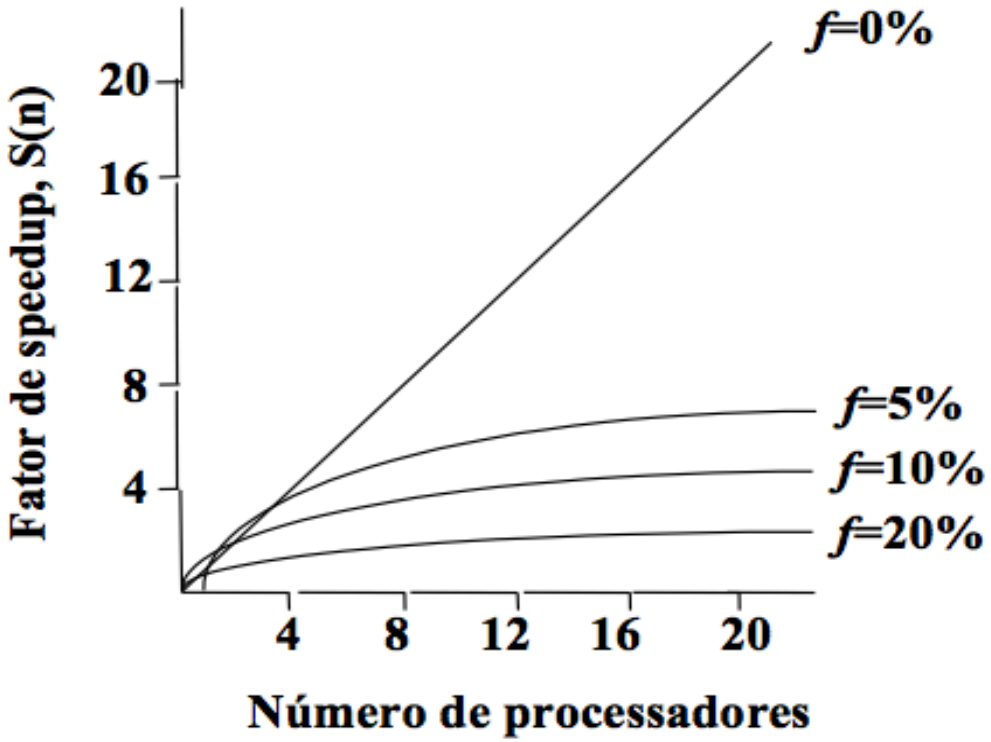

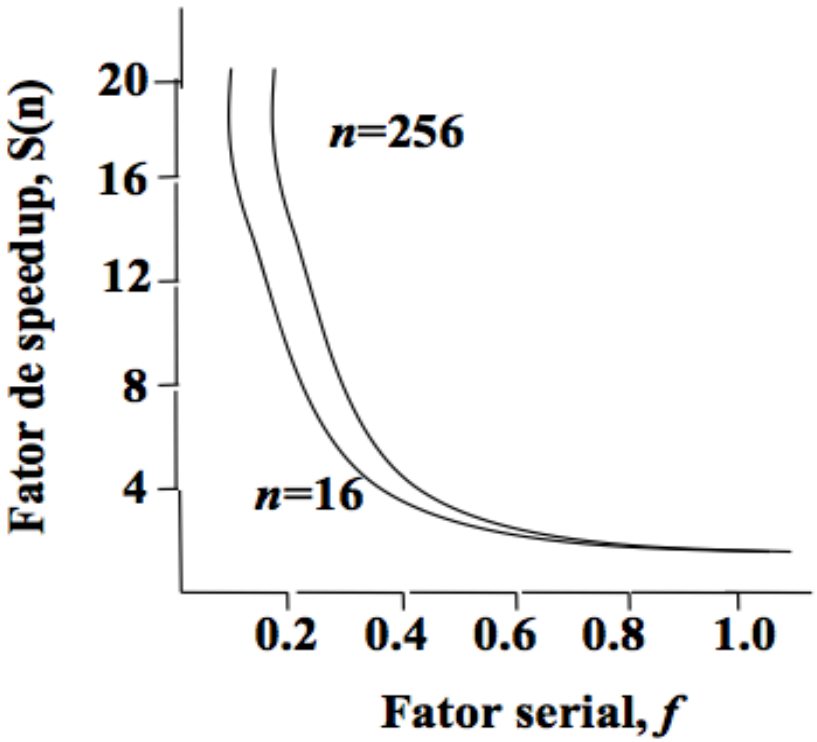

Escalabilidade

- Escalabilidade de hardware ou de arquitetura
  - Aumento do tamanho do sistema impacta no desempenho
  - Facilidade de agregar processadores
- Escalabilidade do algoritmo paralelo
  - Algoritmo pode suportar um aumento do tamanho do problema
    - Exemplo: adição de matrizes: duplica o tamanho da matriz, duplica o número de passos
    - Exemplo: multiplicação de matrizes: duplica o tamanho da matriz, quadruplica o número de passos
    - Exemplo: aumentar a precisão do tempo

Lei de Gustafson (1988)

- Análise da Lei de Amdahl considerando escalabilidade
- Considera que o tempo de execução paralela é fixo, assim como ft
  - Parte serial é fixa sendo independente da carga
  - **“pode-se resolver problemas maiores no mesmo intervalo de tempo”**
- Speed up = s + Np

Lei de Gustafson (1988)

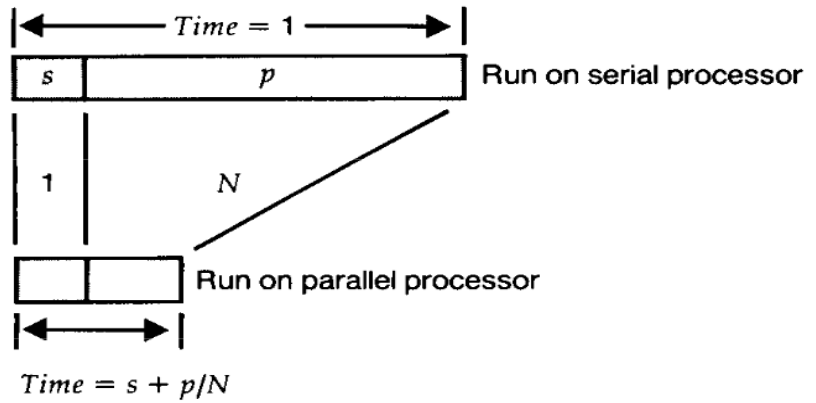

FIGURE 2a. Fixed-Sized Model for $Speedup = 1/(s + p/N)$

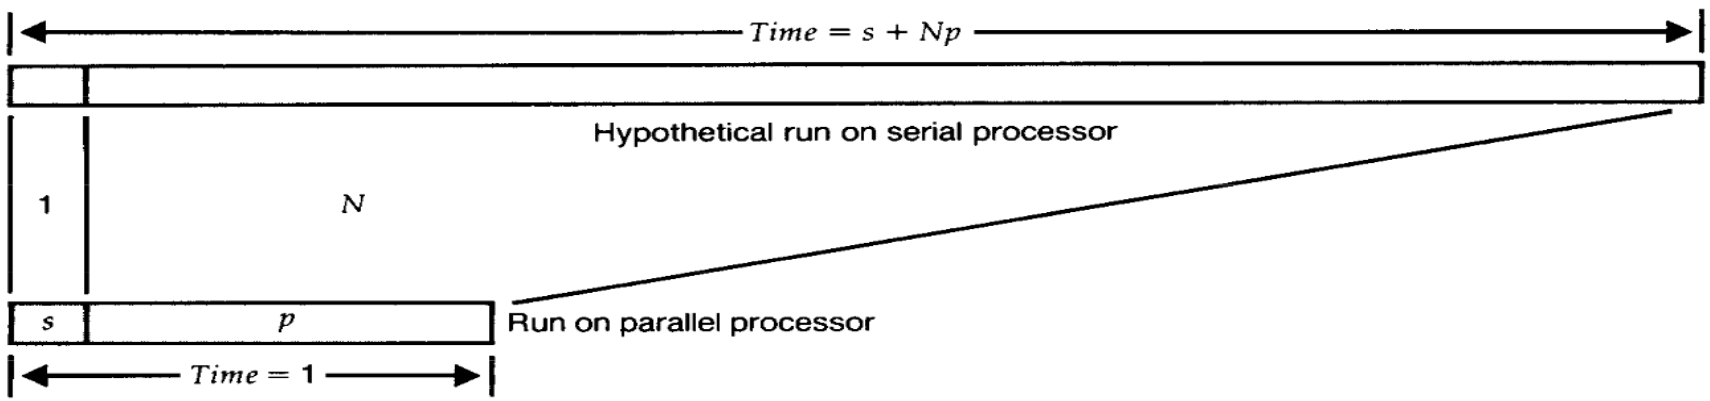

FIGURE 2b. Scaled-Sized Model for $Speedup = s + Np$

Considerações finais

- Teoricamente, o speedup nunca pode exceder o número de elementos de processamento p
- Na prática ocorre o fenômeno conhecido como superlinear speedup
  - O trabalho realizado por um algoritmo sequencial é maior que sua formulação paralela
  - Características de hardware (exemplo: cache)
- Somente um sistema paralelo ideal contendo p elementos de processamento pode fornecer um speedup igual a p
- Na prática não é atingido pois os elementos de processamento não dedicam 100% de tempo para a execução do programa